



ANÁLISIS DE RESEÑAS

Reto 6: Análisis de Sentimiento

Camilo Andres Ortiz Gonzalez, Omar Elian
Martinez Perez







Detección de reseñas negativas para retener clientes

La empresa de electrodomésticos enfrenta el desafío de **identificar reseñas negativas** para mejorar la satisfacción del cliente y disminuir pérdidas.

Datos del Dataset

El dataset **mteb** contiene 210,000 reseñas de Amazon en español, recopiladas entre 2015 y 2019. Este conjunto de datos está balanceado en cinco clases, con un 20% cada una. A través del análisis exploratorio de datos (EDA), se encontraron hallazgos clave: la mediana de palabras por reseña es de 25, y el vocabulario muestra características discriminativas claras entre reseñas extremas, lo que indica la importancia de un modelado preciso para la predicción de sentimientos.






Arquitectura Transformer BETO y sus parámetros de entrenamiento

El modelo BETO utiliza una arquitectura Transformer con fine-tuning, optimizando 110 millones de parámetros para análisis efectivo.


Resultados Clave



En la evaluación del modelo BETO, se logró una **accuracy del 55.05%** sobre un set de 2000 reseñas no vistas. El **F1 macro alcanzó 0.5544**, superando la meta establecida. Los resultados por clase revelan un recall del 63.75% para 1 estrella y del 61.50% para 5 estrellas. La clase más difícil fue la de 3 estrellas, con un recall de 47%, evidenciando la ambigüedad de ciertas reseñas.


Comparación de rendimiento: BETO y modelos base

BETO supera a los modelos básicos como azar y TF-IDF, mostrando un rendimiento notablemente mejorado en F1 macro.



Análisis de Errores

La matriz de confusión revela confusiones entre clases adyacentes, lo cual es **deseable**. Las reseñas de 1 estrella se confunden principalmente con 2 estrellas, mientras que las de 3 estrellas se distribuyen entre 2 y 4. Este comportamiento refleja la ambigüedad inherente de las reseñas neutras. También se identificaron casos donde las etiquetas humanas son incorrectas, como una reseña de 3 estrellas que decía "Un fiasco el teléfono se rompió", clasificada erróneamente como 1 estrella por el modelo.



Predicción de sentimiento y acciones recomendadas

La función evalúa nuevas reseñas y sugiere acciones específicas según el nivel de satisfacción del cliente.

📄 Reseña: 'Cumple su función básica, nada del otro mundo. Por el precio está bien pero esperaba un poco más.'

★ Predicción: 4★ (confianza: 69.7%)

📊 Distribución:

1★:	0.1%
2★:	0.4%
3★:	29.0%
4★:	69.7%
5★:	0.8%

🎯 Acción: ✅ Reseña positiva: agradecer y, si aplica, invitar a reseñar en marketplace público.

📄 Reseña: 'ESTAFA TOTAL. Pagué por una plancha y me llegó una caja vacía. El vendedor no responde mis mensajes.'

★ Predicción: 1★ (confianza: 99.0%)


📊 Distribución:

1★:	99.0%
2★:	0.6%
3★:	0.1%
4★:	0.1%
5★:	0.2%

🎯 Acción: 🚨 URGENTE: contactar al cliente en <24h. Posible riesgo de churn o reseña pública negativa.

Limitaciones y futuro

El modelo presenta **limitaciones significativas** en su capacidad de generalización, especialmente al tratar léxicos de diferentes regiones como LATAM. Además, el sarcasmo y la ironía son desafíos abiertos en el procesamiento del lenguaje natural. La truncación a 128 tokens puede perder información valiosa en reseñas más largas. Como siguiente paso, planeamos entrenar con el dataset completo, lo que se espera que mejore el F1 en 3 a 5 puntos, optimizando el rendimiento general del modelo.



GRACIAS!